



计算机工程

Computer Engineering

ISSN 1000-3428, CN 31-1289/TP

## 《计算机工程》网络首发论文

题目: 基于双重注意力机制和 GRU 的短期负荷预测模型  
作者: 李晓, 卢先领  
DOI: 10.19678/j.issn.1000-3428.0060145  
网络首发日期: 2021-03-10  
引用格式: 李晓, 卢先领. 基于双重注意力机制和 GRU 的短期负荷预测模型. 计算机工程. <https://doi.org/10.19678/j.issn.1000-3428.0060145>



**网络首发:** 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式 (包括网络呈现版式) 排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

**出版确认:** 纸质期刊编辑部通过与《中国学术期刊 (光盘版)》电子杂志社有限公司签约, 在《中国学术期刊 (网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊 (网络版)》是国家新闻出版广电总局批准的网络连续型出版物 (ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。



# 基于双重注意力机制和GRU的短期负荷预测模型

李晓<sup>1,2</sup>, 卢先领<sup>1,2</sup>

1. 江南大学 “轻工过程先进控制”教育部重点实验室, 江苏 无锡 214122;

2. 江南大学 物联网工程学院, 江苏 无锡 214122

**摘 要:** 泛在电力物联网环境下, 针对实际情况中各输入特征对电网负荷情况影响程度的不稳定性, 以及递归神经网络捕获负荷数据长期的时间依赖关系能力差导致的预测精度下降的问题, 提出了一种基于双重注意力机制和 GRU 的短期负荷预测方法。利用特征注意力机制自主分析历史信息与输入特征之间的关联关系, 提取重要特征。时序注意力机制自主选取 GRU 网络关键时间点的历史信息, 提升较长时间段预测效果的稳定性。通过对 3 个公开数据集的实验对比, 结果表明所提模型在预测精度问题上表现良好, 对比支持向量机回归(SVR)、核主成分分析极限学习机(KPCA-ELM)、深度信念网络(DBN)、GRU、Attention-GRU、CNN-LSTM、Attention-CNN-GRU 模型预测精度分别提高了 2.47%、1.14%、1.93%、1.37%、1.04%、0.74%、0.41%。

**关键词:** 时间序列预测; GRU; 特征注意力机制; 时序注意力机制; 短期负荷预测

开放科学(资源服务)标志码(OSID):



## A Short-term Power Load Forecasting Method Based on Dual-stage Attention Mechanism and GRU

LI Xiao<sup>1,2</sup>, LU Xianling<sup>1,2</sup>

1. Key Laboratory of Advanced Process Control for Light Industry, Jiangnan University, Wuxi, Jiangsu 214122, China;

2. College of Internet of Things, Jiangnan University, Wuxi, Jiangsu 214122, China

**Abstract:** Under the environment of Internet of Things in Power Systems, in order to solve the problem of the instability of the influence degree of each input feature on the power grid load condition and the decline of the prediction accuracy caused by the poor ability of the recursive neural network to capture the load data in the long-term time dependence relationship in the actual situation, a short-term load forecasting method based on dual attention mechanism and GRU was proposed. The feature attention mechanism is used to independently analyze the correlation between historical information and input features and extract important features. The temporal attention mechanism independently selects the historical information of key time points in the GRU network to improve the stability of the prediction effect over a long period of time. Through the experimental comparison of three public data sets, the results show that the proposed model performs well in the prediction accuracy problem, compared with support vector machine regression (SVR), KPCA-ELM (kernel principal component analysis extreme learning

基金项目: 江苏省重点研发计划项目(BE2018334)。

作者简介: 李晓(1995—), 男, 硕士研究生, 主要研究方向为负荷预测, E-mail: 957451879@qq.com;

卢先领(1972—), 男, 通信作者, 博士, 教授, 主要研究方向为负荷预测, E-mail: jnluxl@jiangnan.edu.cn。

machine), DBN(deep belief Network), GRU, Attention-GRU, CNN-LSTM, Attention-CNN-GRU model, the prediction accuracy were improved by 2.47%, 1.14%, 1.93%, 1.37%, 1.04%, 0.74%, 0.41% respectively.

**Keywords:** Time series prediction; GRU; Feature attention mechanism; Temporal attention mechanism; Short-term load forecasting

DOI:10.19678/j.issn.1000-3428.0060145

## 0 引言

随着国家大力的推进泛在电力物联网的建设,促使电力系统向高智能,信息化方向发展。电力负荷预测是其中重要的一环,它的结果将对电力系统的部署、规划和运行产生很大的影响。短期负荷预测对电网的日常运行、调度规划等重大决策具有重要影响。因此,为了保证经济效益和社会效益,准确预测电力负荷的能力至关重要,不仅可以保证电力系统的安全,同时也保证了供电企业能够及时、实时地进行供电项目的实时调度<sup>[1]</sup>。

短期电力负荷预测主要进行电力系统未来几小时到一天的用电量预测,由于电力负荷存在随机性和非线性,使得预测难度提升,同时短期负荷又深受实时变化的环境因素(温度、降雨、湿度、光照等)以及用户主观的影响,增加了短期负荷预测的复杂程度,因此精确的短期负荷预测就成了一项极具挑战的任务<sup>[2]</sup>。

许多学者对短期负荷预测进行了大量的研究,其中传统的预测方法有时间序列法<sup>[3,4]</sup>、回归分析法<sup>[5]</sup>等。这些方法的实现原理简单,运算速度快,适合处理结构简单,规模小的数据集。但随着基础设施不断地完善,使得用户规模的不断扩大,电力数据爆发式的增长,同时由于其电力数据本身的非线性,适应性差的特点,传统方法逐渐被放弃,转而机器学习方法因为其强大的适应性和非线性处理能力开始发展壮大。Support Vector Regression(SVR)<sup>[6,7,8]</sup>,神经网络模型<sup>[9]</sup>层出不穷,也展现出了不错的效果。文献[10]引入灰色关联分析改善样本筛选,提高数据利用率,并利用混沌粒子群算法优化完善最小二乘支持向量机的参数选择,能很好的进行负荷预测。文献[11]根据负荷参考指标的非线性提出核主成分分析来改进极限学习机(ELM)神经

网络,降低了输入维数,有效地提高了预测精度。文献[12]提出了一种基于最大偏差相似性准则的BP神经网络短期电力负荷预测算法。改进最大偏差相似性准则,提出使用预测日的负荷特征向量与最大偏差相似性准则算法聚类之后的类中心负荷特征的距离来确定预测日的相似日类别。上述方法将影响居民用电情况参量的相关性加入考虑,突出了重要特征。但由于所采用的关联规则方法依赖于专家经验,导致特征选取的主观性,且无法根据实际情况做出自适应的调整,导致预测时精度的不稳定性。

深度学习算法在处理大数据量问题时具有良好的特征提取能力,而短期负荷预测需要从复杂多变的历史负荷数据中提取典型特征,从而做出准确的负荷预测,所以深度学习方法被广泛应用到短期负荷预测中。文献[13]将深度残差网络应用到负荷预测中,也有很好的泛化能力,但同样也存在缺少研究时序性的问题。通过研究历史负荷数据得知,负荷有明显的周期性规律,因此在研究短期负荷问题时要考虑其时序性。深度学习模型中的LSTM网络,GRU网络能很好的记忆相关历史信息,从而很好的学习负荷的变化情况。文献[14]提出了一种Seq2seq模型,通过LSTM网络构建的编解码器分析用户负荷数据的周期性波动特征,建立负荷数据的相关性进行预测。文献[15]通过隔离森林算法挖掘清理异常历史负荷数据,然后利用LSTM网络学习负荷的时序特性进行预测。文献[16]通过卷积神经网络CNN提取负荷特征,相较于手动提取特征更全面,误差小,并利用LSTM网络学习负荷的长短期依赖关系。文献[17]引入循环神经网络(Recurrent Neural Network,RNN)由于可以很好地捕获在时间上距离很远的数据之间的相关性,并利用Zoneout技术解决梯度消失问题,而且大幅度减少了待训练的网络参数。文献[18]提出了一

种双向 GRU 网络预测模型,通过分析过去和未来的负荷信息学习其周期性和非线性。上述方法虽然能很好的处理负荷在时序上的相关性,但是忽视了实际运行中各输入特征的关联关系,存在片面性。

深度学习中的注意力机制<sup>[19]</sup>是根据人们在处理全局图像时,自主增强焦点区域信息抑制其他冗余区域表达的选择性,来反映全局信息的能力,而衍生出的以从众多信息中自主选择对当前任务更关键信息为核心的一种信息处理方式<sup>[20]</sup>,基于上述原理,针对短期负荷预测的深受实时变化的环境因素与居民自身主观因素影响的问题,设计出特征注意力机制和时序注意力机制,利用特征注意力机制来分析不同输入参量对负荷的重要程度,挖掘出关联关系;同时利用时序注意力机制分析各历史时刻的负荷对待预测时刻负荷的重要程度,来选择关键时间点数据,从而提高预测精度。

本文在 GRU 网络的基础上引入了双重注意力机制,利用特征信息的关联性和时序信息依赖性提升负荷预测的准确率。首先各时刻的原始输入信息结合前一时刻 GRU 网络隐藏状态信息输入到特征注意力机制中,分析得到各输入特征的影响力权重并进行加权得到优化后的输入数据,再通过 GRU 网络学习特征,接着将当前时刻网络的隐藏状态输出结合各历史时刻的隐藏状态输出通过时序注意力机制,分析得到各历史时刻隐藏状态的影响力权重,加权得到优化的当前时刻最终隐藏状态输出,最后通过全连接输出层得到最终预测结果。

## 1 深度学习模型原理

### 1.1 GRU

通过研究历史负荷数据得知,负荷有明显的周期性规律,因此在研究负荷问题时要考虑其时序性。深度学习模型中 LSTM 网络,GRU 网络能很好的记忆相关历史信息,从而很好的学习负荷变化情况。GRU 是对最广泛使用的有很好效果能分析时间序列数据的 LSTM 网络改进而来的,能够捕获长期依赖关系。通过减少和合并门结构单元优化了 LSTM 复杂的内部结构,从而在保证精度的

前提下提高了网络的训练速度<sup>[21]</sup>。LSTM 有输出门,遗忘门和输入门,而 GRU 则只包含更新门和重置门,减少了参数的训练。更新门控制前一时刻的状态信息保留到当前状态中的程度,值越大表示前一时刻的状态信息保留越多。重置门控制当前状态与先前的信息结合的程度,值越小说明忽略的信息越多。




图 1 GRU

Fig.1 Structure of GRU

$$z_t = \sigma(W_z \cdot [X_t, h_{t-1}]) \quad (1)$$

$$r_t = \sigma(W_r \cdot [X_t, h_{t-1}]) \quad (2)$$

$$\tilde{h}_t = \tanh(W_h \cdot [X_t, r_t * h_{t-1}]) \quad (3)$$

$$h_t = (1 - z_t) * h_{t-1} + z_t * \tilde{h}_t \quad (4)$$

式中:  $z_t$  为更新门,  $r_t$  为重置门,  $X_t$  为当前输入,  $\tilde{h}_t$  为输入和过去隐层状态的汇总,  $h_t$  为隐藏层输出,  $W_z$ ,  $W_r$ ,  $W_h$  为可训练参数矩阵。

### 1.2 注意力机制

注意力机制是一种模拟人脑注意力的模型,借鉴了人脑在某个特定时刻对事物的注意力会集中到特定的地方,而减少甚至是忽略对其他部分的注意力。注意力通过对模型的输入特征赋予不同的权重,突出更关键的影响因素,帮助模型做出更加准确的判断。

在特征关联分析方面,利用 GRU 网络分析的前一时刻隐藏状态输出和当前时刻输入特征,通过多层感知机构建的注意力机制分析得出注意力权重,来反映当前各输入特征对待预测信息的重要程度,提高预测模型的



学习效果。

在时序分析方面，注意力机制通过概率分配方式对 GRU 网络各历史时刻进行重要性分析，突出关键时刻输出的比重，帮助模型做出更加准确的预测。

基于上述理论，利用特征注意力机制来分析不同输入参量对负荷的重要程度，挖掘出关联关系；同时利用时序注意力机制分析各历史时刻的负荷对待预测时刻负荷的重要程度，来选择关键时间点数据，从而提高预测精度。

## 2 基于双重注意力机制和GRU的负荷预测模型

### 2.1 特征注意力机制

对人们电力消费行为产生影响的因素有很多，它们时时刻刻都对人们的生活产生影响，同时它们时时刻刻也在变化着，此消彼长，从而，人们的电力消耗力也受之影响。为了探索这些相关因素对人们电力消耗的关联性高低程度，引入了特征注意力机制，采用多层感知机的方法对各特征影响力进行权重的量化。

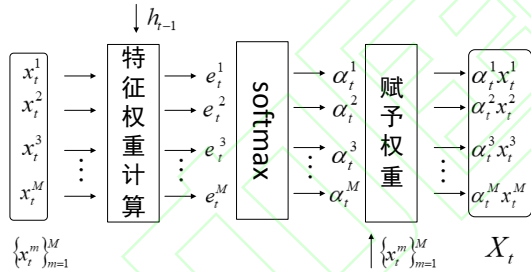


图2 特征注意力机制

Fig.2 Feature Attention Mechanism

将特征的时间序列，前一时刻 GRU 网络的隐藏状态  $h_{t-1}$  和当前时刻输入特征  $x_t^m$  作为特征注意力机制的输入，通过式 (5) 对当前时刻各特征进行注意权重的计算，然后进行式 (6) 的归一化处理，根据注意力权重增强或削弱相关输入信息的表达，将当前时刻得到的权重与对应特征相乘进行特征注意力输出  $X_t$ ，自适应优化相关特征的影响力。

$$e_t^m = V_e^T \tanh(W_e h_{t-1} + U_e x_t^m + b_e) \quad (5)$$

式中：  $V_e \in R^T$ 、  $W_e \in R^{T \times q}$ 、  $U_e \in R^{T \times T}$  为多

层感知机需要学习的神经元权重，  $b_e \in R^T$  偏置参数；  $q$  为编码器 GRU 网络最后一层隐藏层神经元数量。

$$\alpha_t^m = \text{soft max}(e_t^m) = \exp(e_t^m) / \sum_{i=1}^M \exp(e_t^i) \quad (6)$$

$$X_t = (\alpha_t^1 x_t^1, \alpha_t^2 x_t^2, \dots, \alpha_t^M x_t^M)^T \in R^{1 \times M} \quad (7)$$

根据前一时刻 GRU 网络的隐层状态和当前时刻的输入通过特征注意力机制学习当前时刻各输入特征与待预测负荷信息的相关性，自适应处理原始输入的特征，来强化相关特征影响力及弱化不相关特征。

### 2.2 时序注意力机制

鉴于居民当前用电负荷情况受历史状态影响比较大且不同时刻的负荷情况影响力是不同的，为了研究每一历史时刻状态信息对当前预测结果的影响程度，对我们的 GRU 网络输出结果后引入时序注意力机制。自适应处理历史状态信息，强化相关时刻状态信息的影响力。




图3 时序注意力机制

Fig.3 Temporal Attention Mechanism

以包含各历史时刻信息的最后一层隐层状态作为时序注意力机制的输入，分析历史状态与当前状态的关联性，并赋予影响权重。score 评分函数采用点积；  $\alpha_{ti}$  为历史输入的隐藏层状态对当前输入的注意力权重；  $c_t$  是中间向量；  $\tilde{h}_t$  表示最终输出的当前时刻的隐

藏层状态值。

$$\text{score}(h_t, h_i) = h_t^\top h_i \quad (8)$$

$$\alpha_{t,i} = \exp(\text{score}(h_t, h_i)) / \sum_{k=1}^{T_x} \exp(\text{score}(h_t, h_k)) \quad (9)$$

$$c_t = \sum_{i=1}^{T_x} \alpha_{t,i} h_i \quad (10)$$

$$\tilde{h}_t = \tanh(W_c[c_t; h_t]) \quad (11)$$

## 2.3 基于双重注意力机制和GRU模型

双重注意力机制 GRU 模型包括输入向量、特征注意力层、3 层 GRU 网络、时序注意力层、全连接层输出。输入向量结合前一时刻 GRU 网络的隐藏状态经过特征注意力层计算得到各特征量对当前预测情况的影响权重并得到修正后的输入特征，经过两层 GRU 网络学习特征，再通过时序注意力层计算出各历史时刻输出信息的影响权重并得到改进后的当前时刻隐层状态输出，最后输入到全连接层得到最终预测结果。如图 4。

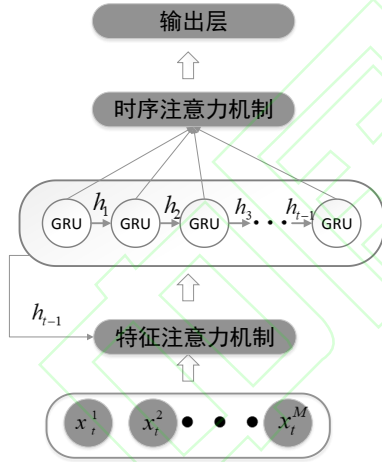


图 4 基于双重注意力机制 GRU 模型结构

Fig.4 Structure of Method Based on Dual-stage Attention Mechanism and GRU

原始输入信息和前一时刻 GRU 网络输出通过注意力机制计算出当前时刻输入的各特征对本次预测的权重，赋予原始输入信息对应权重得到新的输入信息。接着输入的 GRU 网络中学习特征，GRU 网络可以随着层数的增加使得它的非线性拟合能力也会提高，学习效果越好。但考虑到训练时间的问题，层数的选择也要适中。本实验设置 3 层 GRU 网络，第一层设置 128 个神经元，来更

好的学习特征。第二层设置 64 个神经元减少冗余数据的干扰，第三层 29 个神经元。时间步长为 24，学习率为 0.001，训练周期 1000 次。之后，将当前时刻网络输出结合历史输出经过注意力机制分析所以输入特征对我们预测的影响权重，突出关键时刻的影响因素，得到新的输出向量。最后通过全连接层得到预测结果。

## 3 算例分析

### 3.1 数据集

本文采用了 3 个真实的电力负荷数据集验证模型性能，分别为美国纽约电力市场（2018-2020）电力数据、印度旁遮普省电力消耗（2019-2020）、美国德克萨斯州电力可靠性委员会（2006-2012）电力数据。包括：24 点负荷数据(kw)，温度(℃)，湿度(%)，光强(lx)，降雨量(mm)，节假日情况(工作日为 1，休息日为 0)。以间隔为 1 小时采集一次数据，一天 24 个。本文将与 SVR、KPCA-ELM(kernel principal component Analysis-extreme learning machine)、DBN(deep belief network)、GRU、Attention-GRU、CNN-LSTM、Attention-CNN-GRU 模型做为对比方法。SVR 采用径向基核函数(RBF)，惩罚因子为 1000；KPCA-ELM 设置 5 个主成分，ELM 为单隐藏层结果；DBN 采用[25,25,25]的三层隐藏层结构；GRU 采用[29, 29, 29]的三层隐藏层结构，时间步长为 24，学习率为 0.001，训练周期 1000 次。单注意力机制 GRU 采用的[24, 24, 24]三层隐藏结构，时间步长 24，训练迭代次数为 1000 次，学习率为 0.001；Attention-CNN-GRU 构建由 2 个卷积层、2 个池化层和全连接层组成的 CNN 框架。为了保证实验的有效性和可靠性，所有方法的实验条件都相同。

### 3.2 评价指标

误差指标采用平均绝对百分比误差(mean absolute percentage error, MAPE)和均方根误差(root mean square error, RMSE)，公式如下：

$$e_{MAPE} = \frac{1}{n} \sum_{i=1}^n \frac{|l_i - \hat{l}_i|}{l_i} \times 100\% \quad (12)$$

$$e_{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (l_i - \hat{l}_i)^2} \quad (13)$$

式中： $n$  为预测点个数， $l_i$  表示第  $i$  点的真实值， $\hat{l}_i$  表示第  $i$  点的预测值。

### 3.3 实验结果与分析

#### 3.3.1Mendeley data 实验结果对比

本文将美国纽约电力市场电力数据 2018-2019 年作为训练数据，2020 年作为测试数据。各模型预测误差如表 1 所示。

表 1 不同模型预测精度比较

Different Models		
模型	$e_{MAPE}/\%$	$e_{RMSE}/\text{kW}$
本文方法	3.82	107.16
SVR	6.47	238.65
KPCA-ELM	5.14	183.84
DBN	6.07	236.41
GRU	5.48	214.91
CNN-LSTM	5.11	167.73
Attention-GRU	4.87	156.47
Attention-CNN-GRU	4.47	133.86

实验结果显示，本文方法误差在 3.82%，优于其他方法，分别降低了 2.65%、1.32%、2.25%、1.66%、1.29%、1.05%、0.65%。RMSE 也小于其他方法，可见本文方法比传统机器学习、深度学习方法有更好的预测效果，同时也优于传统关联分析与神经网络相结合的方法，本文的方法可以取得更好的预测效果。

#### 3.3.2Kaggle datasets 实验结果对比

本文将印度旁遮普省电力消耗（2019-2020）前 18 个月作为训练数据，后 6 个月作为测试数据。各模型预测误差如表 2 所示。

表 2 不同模型预测精度比较

Different Models		
模型	$e_{MAPE}/\%$	$e_{RMSE}/\text{kW}$
本文方法	3.17	89.12
SVR	5.84	183.81
KPCA-ELM	4.61	138.41
DBN	5.21	164.73
GRU	4.68	155.73
CNN-LSTM	4.16	114.73
Attention-GRU	3.86	108.75
Attention-CNN-GRU	3.53	103.84

实验结果显示，本文方法误差在 3.17%，优于其他方法，分别降低了 2.67%、1.44%、2.04%、1.51%、0.99%、0.69%、0.36%。充

分证明了本文方法实验的准确性。




图 5 负荷曲线图

Fig.5 Curve of Load

为了更直观的展示本文方法的准确性，图 5 给出了印度旁遮普省某日上午的电力负荷数据的各方法的预测曲线，从图中可以看出，各方法都能预测到曲线的走势，总体上误差相差不大，但是随着时间的推移，到了负荷最低点，差异就体现了出来。传统方法 SVR、GRU、DBN 误差都较大，Attention-GRU、CNN-LSTM、KPCA-ELM 略优，虽然 Attention-CNN-GRU 效果也很好，但本文提出的方法误差更小，准确率更高。综合分析，本文方法性能最优。

#### 3.3.3ERCOT datasets (2006-2012) 数据集实验结果对比

本文将美国得克萨斯州电力可靠性委员会（2006-2012）电力数据 06-09 年作为训练数据，10-12 年作为测试数据。各模型预测误差如表 3 所示。

表 3 不同模型预测精度比较

Different Models		
模型	$e_{MAPE}/\%$	$e_{RMSE}/\text{kW}$
本文方法	2.67	107.754
SVR	4.77	251.131
KPCA-ELM	3.32	228.431
DBN	4.18	244.847
GRU	3.62	237.464
CNN-LSTM	3.52	230.471
Attention-GRU	3.15	189.437
Attention-CNN-GRU	2.89	143.178

实验结果表明,本文方法的预测精度达到 97.33%, 好于其他七种方法, 分别减少了 2.1%、0.65%、1.51%、0.95%、0.85%、0.48%、0.22%。RMSE 也低于其他方法, 分别降低了 143.377kW、120.677kW、137.093kW、129.71kW、122.717kW、81.683kW、35.424kW。综合分析, 本文方法在 MAPE 和 RMSE 都有显著减少, 表明了该模型的预测性能优于其他方法。

为验证特征注意力机制自适应挖掘各特征参量的关联性, 对训练完成的模型进行实验, 提取某日 24 时的特征分析情况。关系热力图如图 6 所示。每个方块的颜色表征其行对应的待预测数据和其列对应的某相关特征参量的相关性分数, 每行所有方块表征的相关性分数和为 1, 方块的颜色代表相关性分数的高低, 颜色越浅, 对应的特征与待测数据越相关, 对待测数据影响力越大。




图 6 负荷关联特征热力图

Fig.6 Association heat map of load

由图 6 可知, 节假日所对应的热力图颜色很淡, 它对用户负荷情况影响很大。而温度所对应的热度图, 在午间时分颜色越来越淡, 可知午间温度很高的时候对我们负荷的影响也很大。而湿度则是对负荷的影响不是很大, 只在早晨和夜晚时分略有影响。光强对负荷的影响主要也是在正午光照最强的时候, 天气晴朗时降雨就少, 对负荷的影响也小。总体关联关系较为符合居民用电规律。




图 7 负荷曲线

Fig.7 Curve of Load

为了更直观的展示本文方法的准确性, 如图 7 所示是美国德州某日的数据集预测结果对比。各方法都能预测到曲线的走势, 误差相差不大, 但是到了负荷最低点, 误差开始增大。传统方法 SVR、GRU、DBN 误差都较大, Attention-GRU、CNN-LSTM、KPCA-ELM 略优, 虽然 Attention-CNN-GRU 效果也很好, 但本文提出的方法误差更小, 准确率更高。同时在最高负荷点, 各方法的误差也有所增加, 但本文的方法预测精度相对更高。

## 4 结论

本文提出了基于双重注意力机制和 GRU 的短期负荷预测方法。能够针对多变的输入特征通过特征注意力机制分析相关特征的重要性, 优化输入特征, 同时通过时序注意力机制结合历史信息分析负荷的时序特性, 挖掘关键历史信息, 优化模型的输出, 提高模型准确性。实验结果表明本文的算法很好的解决了先前存在的问题, 提高了预测精度。在下一阶段的研究中, 寻找更优的参考特征, 并优化注意力模型, 提高关联分析能力, 最终能更进一步提高短期负荷预测的精度。

## 参考文献

- [1] AKKAR HA, ALI WH (2018) Estimation load forecasting based on the intelligent systems[J]. Al-Nahrain J Eng



- Sci,2018, 21(2):285-291
- [2] Chen J , Li T , Zou Y , et al. An Ensemble Feature Selection Method for Short-Term Electrical Load Forecasting[C]// 2019 IEEE 3rd Conference on Energy Internet and Energy System Integration (EI2). IEEE, 2019.
- [3] LANG Kun, ZHANG Mingyuan, YUAN Yongbo, et al. Short-term load forecasting based on multivariate time series prediction and weighted neural network with random weights and kernels[J]. Cluster Computing, 2018, 22(12):12589-12597.
- [4] J. C. López, M. J. Rider and Q. Wu, Parsimonious Short-Term Load Forecasting for Optimal Operation Planning of Electrical Distribution Systems[J]. IEEE Transactions on Power Systems, 2019,34(02):1427-1437.
- [5] BRACALE A, CARAMIA P, DE FALCO P. & HONG T, Multivariate Quantile Regression for Short-Term Probabilistic Load Forecasting[J]. IEEE Transactions on Power Systems, 2020,35(1):628-638.
- [6] 汤强,谢明中,罗元盛.基于 SVR 的用电负荷特征三维回归模型[J].计算机工程,2017,43(09):300-303+309.
- TANG Qiang, XIE Mingzhong, LUO Yuansheng. SVR Based Three Dimensional Regression Model of Power Load Characteristics[J].Computer Engineering,2017,43(09):300-303+309.
- [7] 郭艳飞,程林,李洪涛,饶强,刘满君.基于支持向量机和互联网信息修正的空间负荷预测方法[J].中国电力,2019,52(04):80-88.
- GUO Yanfei, CHENG Lin, LI Hongtao, RAO Qiang, LIU Manjun.Spatial Load Forecasting Method Based on Support Vector Machine and Internet Information Correction[J]. Electric Power,2019,52(04):80-88.
- [8] H. Jiang, Y. Zhang, E. Muljadi, J. J. Zhang and D. W. Gao. A Short-Term and High-Resolution Distribution System Load Forecasting Approach Using Support Vector Regression With Hybrid Parameters Optimization[J]. IEEE Transactions on Smart Grid,2018,9(4): 3341-3350.
- [9] F. Y. Xu, X. Cun, M. Yan, H. Yuan, Y. Wang and L. L. Lai. Power Market Load Forecasting on Neural Network With Beneficial Correlated Regularization[J]. IEEE Transactions on Industrial Informatics,2018,14(11):5050-5059.
- [10] 唐玮,钟士元,舒娇,王敏.基于 GRA-LSSVM 的配电网空间负荷预测方法研究[J].电力系统保护与控制,2018,46(24):76-82.
- TANG Wei, ZHONG Shiyuan, SHU Jiao. Research on spatial load forecasting of distribution network based on GRA-LSSVM method[J]. Power System Protection and Control,2018,46(24):76-82.
- [11] 董浩,李明星,张淑清, et al.基于核主成分分析和极限学习机的短期电力负荷预测[J].电子测量与仪器学报,2018,32(1):188-193.
- Dong Hao, LI Mingxing, ZHANG Shuqing, et al. Short-term power load forecasting based on kernel principal component analysis and extreme learning machine[J]. Journal of Electronic Measurement and Instrument,2018, 42(20):73-78.
- [12] 罗育辉,蔡延光,戚远航,黄何列.基于最大偏差相似性准则的 BP 神经网络短期电力负荷预测算法[J].计算机应用研究,2019,36(11):3269-3273.
- Luo Yuhui, Cai Yanguang, Qi Yuanhang, et al. Short-term power load forecasting algorithm based on maximum deviation similarity criterion BP neural network[J]. Application Research of

- Computers,2019,36(11):3269-3273.
- [13] K. Chen, K. Chen, Q. Wang, Z. He, J. Hu and J. He. Short-Term Load Forecasting With Deep Residual Networks[J]. IEEE Transactions on Smart Grid,2019,10(4):3943-3952.
- [14] Gong G , An X , Mahato N K, et al. Research on Short-Term Load Prediction Based on Seq2seq Model[J]. Energies, 2019, 12(16):3199.
- [15] Ma Y , Zhang Q , Ding J , et al. Short Term Load Forecasting Based on iForest-LSTM[C]// 2019 14th IEEE Conference on Industrial Electronics and Applications (ICIEA). IEEE, 2019.
- [16] 陆继翔,张琪培,杨志宏,涂孟夫,陆进军,彭晖.基于 CNN-LSTM 混合神经网络模型的短期负荷预测方法[J].电力系统自动化,2019,43(08):131-137.
- LU Jixiang ZHANG Qipei YANG Zhihong TU Mengfu LU Jinjun PENG Hui. Short-term Load Forecasting Method Based on CNN-LSTM Hybrid Neural Network Model[J]. Automation of Electric Power Systems,2019,43(08):131-137.
- [17] 庄世杰,於志勇,郭文忠,黄昉菀.基于 Zoneout 的跨尺度循环神经网络及其在短期电力负荷预测中的应用[J].计算机科学,2020,47(09):105-109.
- ZHUANG Shijie, YU Zhiyong, GUO Wenzhong,, et al. Short Term Load Forecasting via Zoneout-based Multi-time Scale Recurrent Neural Network[J]. Computer Science,2020,47(09):105-109.
- [18] Tang Xianlun, Dai Yuyan, Wang Ting,et al. Short-term power load forecasting based on multi-layer bidirectional recurrent neural network[J]. IET Generation, Transmission & Distribution,2019, 13(17):3847-3854.
- [19] 周雨佳,窦志成,葛松玮,文继荣.基于递归神经网络与注意力机制的动态个性化搜索算法 [J]. 计算机学报,2020,43(05):812-826.
- ZHOU Yu-Jia, DOU Zhi-Cheng, GE Song-Wei, et al. Dynamic Personalized Search Based on RNN with Attention Mechanism[J]. Chinese Journal of Computers,2020,43(05):812-826.
- [20] 杜圣东,李天瑞,杨燕,王浩,谢鹏,洪西进.一种基于序列到序列时空注意力学习的交通流预测模型[J]. 计算机研究与发展,2020,57(08):1715-1728.
- Du Shengdong, Li Tianrui, Yang Yan, et al. A Sequence-to-Sequence Spatial-Temporal Attention Learning Model for Urban Traffic Flow Prediction[J]. Journal of Computer Research and Development,2020, 57(08):1715-1728.
- [21] Wang Y, Liao W, Chang Y. Gated recurrent unit network-based short-term photovoltaic forecasting[J].Energies,2018, 11(8):1-14.