

# 基于改进 GRU 的短期电力负荷预测方法

龚田李慧, 刘 辉

(湖北工业大学, 湖北 武汉 430068)

**摘要:** 为提高电力负荷预测的准确性, 采用灰狼优化 (Grey Wolf Optimizer, GWO) 算法对门控循环单元 (Gated Recurrent Unit Neural Network, GRU) 神经网络进行优化, 并进行短期电力负荷预测。首先预处理数据并量化影响因素, 然后搭建基于 GWO 超参数优化的 GRU 神经网络模型, 最后与其他模型对比得出预测结果。实验结果显示, 该方法拟合度高, 收敛速度快, 有较好的预测效果。

**关键词:** 短期电力负荷预测; 灰狼算法; 门控循环单元; 神经网络

## Short-Term Power Load Forecasting Method Based on Improved GRU

GONG Tianlihui, LIU Hui

(Hubei University of Technology, Wuhan 430068, China)

**Abstract:** In order to improve the accuracy of power load forecasting, this paper uses the Grey Wolf Optimizer (GWO) algorithm to optimize the Gated Recurrent Unit Neural Network (GRU) neural network and perform short-term power load forecasting. First, preprocess the data and quantify the influencing factors, then build a GRU neural network model based on GWO optimized hyperparameters, and finally compare with other models to get the prediction results. The experimental results show that the method has a high degree of fit, a fast convergence rate, and a good prediction effect.

**Keywords:** short-term power load forecasting; gray wolf algorithm; gated recurrent unit; neural network

## 0 引言

随着全球电力系统规模的不断扩大与发展, 人类对于用电设备和用电质量的需求也不断增长<sup>[1]</sup>。电力负荷预测是对电力负荷变化进行的预先估计和测算, 其中包括时间分布和空间分布。短期负荷预测的有效结果可以帮助各能源集团制定合理的发电, 输电和配电计划既能确保安全, 又能在供需之间保持平衡, 减少浪费的资源和电力成本<sup>[2]</sup>。因此, 短期电力负荷预测的研究已成为电网智能化运行和管理的重要研究方向。

短期电力负荷预测常用的预测方法随着智能电网的发展有了很大的改变, 主要可以分为传统统计方法和机器学习方法两类<sup>[3]</sup>。

传统统计方法的理论基础扎实, 模型的建立相对简单。其中, 回归分析法, 时间序列法以及指数平滑法等方法都被广泛应用于电力负荷预测<sup>[4]</sup>。机器学习方法通过自主学习能较好地拟合输入与输出之间的非线性关系。其中, 随机森林 (Random Forest)、支持向量回归 (Support Vector Regression, SVR) 以及长短期记忆网络 (Long Short-Term Memory, LSTM) 等模型在进行电力负荷预测时取得了不错的效果<sup>[5]</sup>。

如文献 [6] 基于模糊信息粒化与支持向量机的模型来进行空间负荷预测, 并证明了该方法的有效性。

然而, 短期电力负荷预测是非线性且不稳定的时间序列问题。当使用统计方法时, 虽然模型的建立较为简单, 但负荷数据的非线性特征不能被准确地反映出来, 而机器学习方法虽然可以很好地处理非线性问题, 但无法有效反映数据在时序上的特征<sup>[7]</sup>。其中, 长短期记忆网络是一种广泛使用的递归神经网络 (Recurrent Neural Network, RNN), 相比于传统的 RNN 网络, 它对数据在时序上的学习与处理能力较强, 但也因此, LSTM 网络的参数也更多, 模型的收敛速度有所降低<sup>[8,9]</sup>。门控循环单元 (Gated Recurrent Unit, GRU) 是基于 LSTM 进行内部单元结构优化的神经网络, 其收敛速度更快, 因此更适用于负荷预测领域<sup>[10]</sup>。GRU 网络适合处理时间序列数据, 但是在进行电力负荷预测时, 其模型参数难以确定, 因此考虑结合其他算法来优化网络结构及参数, 提高模型处理数据的能力。

本文提出了一种基于灰狼优化 (Grey Wolf Optimizer, GWO) 算法的 GRU 神经网络短期负荷预测模型, 记为 GWO-GRU 模型。该模型利用 GWO 算法对 GRU 神经的超参数进行智能寻优, 在一定程度上提高了模型的拟合能力, 最后通过实例分析和其他模型的预测结果比对, 验证了该模型的可行性和高效性。

收稿日期: 2021-01-20

作者简介: 龚田李慧 (1997-), 女, 湖北荆州人, 硕士研究生, 主要研究方向为电气工程;

刘 辉 (1962-), 男, 博士, 教授, 主要研究方向为电气工程、智能控制、系统分析与集成。

## 1 理论基础

### 1.1 灰狼算法

灰狼优化算法是一种新型智能优化算法，是Mirjalili.S等人受到了灰狼狩猎行为启发而提出的一种优化搜索方法。GWO算法将灰狼种群由高到低分为4个等级，由 $\alpha$ 、 $\beta$ 、 $\delta$ 狼引导完成猎食，即优化<sup>[11]</sup>。追踪和围捕由剩下的 $\omega$ 狼追随前三者进行。 $\alpha$ 、 $\beta$ 以及 $\delta$ 的解分别对应最优解、次优解及次次优解。灰狼种群以包围猎物的方式寻找最佳的狩猎路径，优化过程的数学模型表示为：

$$D=|cX_p(t)-X(t)| \quad (1)$$

$$X(t+1)=X_p(t)-AD \quad (2)$$

$$A=2ar_1-a \quad (3)$$

$$c=2r_2 \quad (4)$$

式中， $D$ 是灰狼与猎物间的距离矩阵； $t$ 是当前迭代的次数； $X(t)$ 是灰狼的位置向量； $X_p(t)$ 是猎物的位置向量； $A$ 是随机向量； $c$ 是常量因子； $a$ 是收敛向量，由2线性降到0； $r_1$ 和 $r_2$ 为 $[0,1]$ 的随机数。

通过调整 $A$ 向量和 $c$ 因子，更新灰狼位置，其位置更新公式为：

$$\begin{cases} D_\alpha = |c_1 X_\alpha(t) - X_\omega(t)| \\ D_\beta = |c_2 X_\beta(t) - X_\omega(t)| \\ D_\delta = |c_3 X_\delta(t) - X_\omega(t)| \end{cases} \quad (5)$$

$$\begin{cases} X_1 = X_\alpha - A_1 D_\alpha \\ X_2 = X_\beta - A_2 D_\beta \\ X_3 = X_\delta - A_3 D_\delta \end{cases} \quad (6)$$

$$X_\omega(t+1) = \frac{(X_1 + X_2 + X_3)}{3} \quad (7)$$

式中， $X_1$ 、 $X_2$ 、 $X_3$ 分别表示 $\alpha$ 、 $\beta$ 以及 $\delta$ 狼的位置； $X_\omega(t+1)$ 表示灰狼个体更新后的位置。

### 1.2 GRU神经网络

GRU网络是LSTM网络的改进模型，其模型结构如图1所示，它优化了LSTM的门函数，将遗忘门和输入门组合在一个更新门中。更新门既包含神经元状态又包含隐藏状态，这可以降低网络单元的复杂程度，减少参数数量，大大缩短了模型的训练时间<sup>[12]</sup>。

GRU网络参数的数学表达为：

$$\begin{cases} z_t = \sigma(W_z[h_{t-1}, x_t]) \\ r_t = \sigma(W_r[h_{t-1}, x_t]) \\ \tilde{h}_t = \phi(W[h_t, x_t]) \\ h_t = (1 - z_t)h_{t-1} + z_t\tilde{h}_t \end{cases} \quad (8)$$




图1 GRU网络的模型结构

式中， $x_t$ 输入量； $h_{t-1}$ 和 $h_t$ 分别为上一时刻与这一时刻的状态变量； $r_t$ 是更新门； $z_t$ 是重置门， $\tilde{h}_t$ 是候选集； $W_z$ 、 $W_r$ 以及 $W$ 为权重参数； $\sigma(\cdot)$ 为Sigmoid激活函数； $\phi(\cdot)$ 为Tanh激活函数。

$\sigma(\cdot)$ 和 $\phi(\cdot)$ 可用以下数学公式表达：

$$\sigma(x) = \frac{1}{1+e^{-x}} \quad (9)$$

$$\phi(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (10)$$

GRU神经网络在训练数据时需要很多参数进行设定，在对短期电力负荷进行预测时，神经元数量 $m$ 和时间步长 $T$ 对该模型的影响较大，对神经网络的拟合程度和预测精度有一定影响<sup>[13]</sup>。在本文中，使用GWO算法优化这些超参数，根据输入的数据来优化神经网络的结构并缩短神经网络的训练时间。

## 2 短期电力负荷预测模型

### 2.1 数据预处理

原始的负荷数据与温度数据是不同维度的数据序列，对数据集的训练有一定影响，为了解决不同数据维度不同的问题，需要对数据集进行标准化处理。本文对原始数据进行归一化处理为：

$$a^* = \frac{a - a_{\min}}{a_{\max} - a_{\min}} \quad (11)$$

式中， $a$ 、 $a^*$ 分别为归一化前后的数据； $a_{\max}$ 和 $a_{\min}$ 分别为试验数据的最大值和最小值。

另外，通常电力负荷数据在不同因素影响下变化情况会有较大差别，本文将各种影响因素进行了量化处理。预处理后的部分数据如表1所示，影响因素的量化标准如表2所示。

### 2.2 GWO-GRU模型的搭建

GRU神经网络模型的结构包括输入层，隐藏层以及输出层3个部分。其中，隐藏层的参数设定对GRU神经网络的训练效果有极大影响，因此在对网

表 1 处理前后的部分负荷数据

时间	原始数据			处理后数据		
	11 月 1 日	11 月 2 日	11 月 3 日	11 月 1 日	11 月 2 日	11 月 3 日
0: 00	1 392.11	1 456.71	1 421.65	0.138	0.195	0.201
0: 15	1 438.94	1 447.84	1 472.94	0.200	0.183	0.271
0: 30	1 463.21	1 419.83	1 383.19	0.232	0.142	0.148
0: 45	1 366.86	1 418.98	1 428.11	0.105	0.141	0.209
23: 45	1 501.42	1 537.52	1 427.25	0.283	0.311	0.208

表 2 影响因素量化标准

影响因素	量化标准
日期	周一至周五为 0.5, 周六为 0.6, 周日为 0.7
天气	晴、多云、雾为 1, 阴、小雨、中雨为 2, 大雨、雷阵雨、雨夹雪为 3
风向	西南、西北、东北、东南、东、南、西、北分别为 1 ~ 8
风力	小于等于 3 级为 1, 4 ~ 6 级为 2, 大于等于 7 级为 3

络进行训练时需要优化和调整 GRU 神经网络模型结构的超参数, 包括隐藏层的数量和隐藏层中神经元的数量等。从理论上讲, 隐藏层的数量和隐藏层中神经元的数量越多, 网络越复杂, 神经网络模型的预测精度就越高<sup>[14]</sup>。但在实际应用中, 隐藏层的数量和隐藏层中神经元的数量过多会增加模型的复杂程度, 容易引起过拟合, 从而降低预测的准确性。同时, 太简单的网络很容易因为数据不足而使得训练效果不佳, 达不到预期的要求。另外, 学习率、时间步长以及最大迭代次数等超参数的合理选择可以在一定程度上降低模型的复杂性, 并提高收敛速度和模型预测的准确性<sup>[15-18]</sup>。灰狼算法具有收敛性能高、设置参数少、速度快以及易于实现等特点, 可以根据输入数据训练并优化 GRU 神经网络的结构和超参数, 得到预测精度更高的短期电力负荷预测模型<sup>[19]</sup>。

本文选择的 GRU 网络模型中, 有两个参数对算法的性能有着重要影响, 分别为 GRU 的神经元数量  $m$  和时间步长  $T$ 。将这两个关键参数作为粒子寻优的特征, 利用 GWO 算法对 GRU 模型进行调整优化, 具体步骤如下。一是给定 GRU 神经网络的部分超参数, 如网络节点、隐藏层层数以及批处理大小等, 将 GRU 神经网络的神经元数量  $m$  和时间步长  $T$  初始化后输入 GWO 算法中。二是初始化灰狼的种群规模、变量的上限值和下限值、学习率、最大迭代次数以及 4 只灰狼的初始位置, 并随机生成随机向量  $A$ 、收敛向量  $a$  以及  $c$  常量因子。三是通过 GWO 算法进行优化训练, 寻找最佳狩猎路径, 计算距离矩阵, 得到并记录最佳的位置向量, 更新其他灰狼的个体位置、随机向量  $A$ 、收敛向量  $a$  以及  $c$  常量因子。四是当经过 GWO 算法训练后的参数满足设定条件时停止迭代,

输出最佳参数值, 否则返回第三步, 继续训练。五是将经过 GWO 算法优化后的超参数作为 GRU 神经网络的初始超参数输入 GRU 神经网络中进行训练, 输出预测值, 得到预测数据与测试数据的拟合曲线。

### 3 仿真分析

#### 3.1 算例描述

本文 GWO-GRU 模型构建及训练在 MATLAB R2019b 环境下运行, 算例数据来源于某地区 15 min 粒度的负荷供电数据。采用 10 个月的实际运行数据为例进行算例分析, 以第 1 天至第 293 天的数据作为训练集, 第 3 天至第 296 天的数据作为测试集, 预测未来 3 天每 15 min 的电力负荷数据。

#### 3.2 评价指标

为了更精准地评价模型的预测程度, 本文选取平均绝对百分比误差 (Mean Absolute Percent Error, MAPE) 和均方根误差 (Root Mean Square Error, RMSE) 作为评价指标, 具体数学表达式为:

$$MAPE = \frac{1}{n} \sum_{i=1}^n \frac{|y_i - \hat{y}_i|}{y_i} \times 100\% \quad (12)$$

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (13)$$

式中,  $n$  表示预测的样本数量;  $y_i$  和  $\hat{y}_i$  分别表示该环境下第  $i$  个采样点的实际电力负荷数据和预测电力负荷数据。在电力负荷预测中, RMSE 和 MAPE 的值越小, 反映预测模型的误差越小。

#### 3.3 仿真结果分析

为验证所提模型的有效性, 将传统 BP 模型、LSTM 模型以及 GRU 模型与本文提出的 GWO-GRU 模型进行对比。本文依据数据集选取了恰当的参数进

行了仿真实验，将其中较优的预测结果进行对比，各个不同预测模型的误差评价指标具体数据见表3。

表3 各模型预测结果对比

预测模型	MAPE/(%)	RMSE
BP	2.34	149.03
LSTM	2.21	143.76
GRU	2.16	138.91
GWO-GRU	1.58	98.84

由表3中的预测结果数据可以看出，本文提出的GWO-GRU模型预测精度最高，预测结果最稳定。比起单一的BP模型、LSTM模型以及GRU模型，GWO-GRU模型的RMSE有了明显的降低，预测精度有很大的提升。从预测结果看，GWO-GRU模型的MAPE降低至1.58%，具有更好的预测效果。

各模型在测试集上的预测效果如图2所示，迭代过程如图3所示。




图2 各模型预测结果




图3 迭代过程

观察图3的训练过程可知，在短期电力负荷预测中，GRU模型和GWO-GRU模型在收敛精度和收敛速度上明显优于BP模型和LSTM模型，而GRU模型在迭代到50~100次时很不稳定。总的看来，本文方法具有最好的收敛效果，在学习数据方面占据优势。由图2中的模型预测结果曲线可以看出，本文提出的GWO-GRU模型预测结果最贴近真实值，且波动较小。基于本文使用的数据集，GRU模型在负荷较高时，能取得更好的预测效果，但在负荷较低时预测效果不佳。LSTM模型在负荷波动较大时不能取得良好的预测效果，在负荷波动小时对负荷波动趋势的预测能取得不错的效果。总的来说，GWO-GRU模型

在预测时拟合度较高，具有较好的预测效果。

## 4 结论

本文提出并验证了一种基于灰狼算法改进GRU神经网络模型的短期电力负荷预测方法，通过优化GRU的超参数，提高模型的预测精度。该方法在具有LSTM能有效提取时序特征优点的同时具有更快的收敛速度。本文用某地区15 min粒度负荷数据集进行仿真试验，与BP模型、LSTM模型以及GRU模型进行对比实验发现，所提出的预测模型训练效率与精度都更高，并且能在短期电力负荷预测中取得更好的效果。

(下转第7页)



应控制方法的研究奠定了理论基础与实践基础。

#### 参考文献：

- [1] 程婵娟. 浅析 DF100A 型 100kW 短波发射机控制系统的改进设计 [J]. 信息通信, 2016 (4) : 35-36.
- [2] 王建萍. 关于 DF100A 型 100kW 短波发射机自动化系统分析 [J]. 科学与财富, 2016 (6) : 89.
- [3] 刘莉.MT2000 型小功率短波发射机的常见故障及维修 [J]. 中国新通信, 2019, 21 (24) : 80.
- [4] 张伟生. 基于数字化短波发射机功率反馈控制系统的设计和应用研究 [J]. 电子元器件与信息技术, 2020, 4 (12) : 47-48.
- [5] 张伟生. 2kW 短波发射机无输出功率故障分析 [J]. 中

国有线电视, 2020 (11) : 1337-1339.

- [6] 李文涛. 2 kW 短波广播发射机功率合成网络剖析 [J]. 中国有线电视, 2020 (10) : 1201-1203.
- [7] 张伟生. 浅论小功率短波发射机保护问题研究与分析 [J]. 中国有线电视, 2020 (10) : 1212-1214.
- [8] 符世楠.BGTB5141 型 100kW 短波发射机高速驻波比保护板的原理分析 [J]. 数字传媒研究, 2020, 37 (8) : 39-44.
- [9] 赵彦峰, 马志刚.SW-50B 短波发射机功率开关模块故障原因浅析 [J]. 数字传媒研究, 2020, 37 (6) : 78-79.
- [10] 韩娜. 基于小功率短波发射机维护问题研究与分析 [J]. 卫星电视与宽带多媒体, 2020 (10) : 38-40.

(上接第 4 页)

#### 参考文献：

- [1] 雷敏, 魏务卿, 曾进辉, 等. 考虑需求响应的负荷控制对供电可靠性影响分析 [J]. 电力系统自动化, 2018, 42 (10) : 53-59.
- [2] 王克杰, 张瑞. 基于改进 BP 神经网络的短期电力负荷预测方法研究 [J]. 电测与仪表, 2019, 56 (24) : 115-121.
- [3] 康重庆, 夏清, 刘梅. 电力系统负荷预测 [M]. 北京: 中国电力出版社, 2017.
- [4] Dudek G. Pattern-Based Local Linear Regression Models for Short-Term Load Forecasting [J]. Electric Power Systems Research, 2016, 130: 139-147.
- [5] 杨智宇, 刘俊勇, 刘友波, 等. 基于自适应深度信念网络的变电站负荷预测 [J]. 中国电机工程学报, 2019, 39 (14) : 4049-4061.
- [6] 肖白, 赵晓宁, 姜卓, 等. 利用模糊信息粒化与支持向量机的空间负荷预测方法 [J]. 电网技术, 2021, 45 (1) : 251-260.
- [7] 孔祥玉, 郑锋, 鄂志君, 等. 基于深度信念网络的短期负荷预测方法 [J]. 电力系统自动化, 2018, 42 (5) : 133-139.
- [8] 彭文, 王金睿, 尹山青. 电力市场中基于 Attention-LSTM 的短期负荷预测模型 [J]. 电网技术, 2019, 43 (5) : 1745-1751.
- [9] HE W. Load Forecasting Via Deep Neural Networks [J]. Procedia Computer Science, 2017, 122: 308-314.
- [10] 陈海文, 王守相, 王绍敏, 等. 基于门控循环单元网络与模型融合的负荷聚合体预测方法 [J]. 电力系统自动化, 2019, 43 (1) : 65-72.
- [11] 胡臣辰, 陈贤富. 基于 YOLO 改进残差网络结构的车

辆检测方法 [J]. 信息技术与网络安全, 2020, 39 (9) : 56-60.

- [12] 魏鹭, 茅大钧, 韩万里, 等. 基于 EMD 和长短期记忆网络的短期电力负荷预测研究 [J]. 热能动力工程, 2020, 35 (4) : 203-209.
- [13] Bedi J, Toshniwal D. Empirical Mode Decomposition Based Deep Learning for Electricity Demand Forecasting [J]. IEEE Access, 2018, 6: 49144-49156.
- [14] Srivastava D, Singh Y, SAHOO A. Auto Tuning of RNN Hyper-Parameters Using Cuckoo Search Algorithm [C] // Proceedings of the 12th International Conference on Contemporary Computing, 2019.
- [15] 王增平, 赵兵, 纪维佳, 等. 基于 GRU-NN 模型的短期负荷预测方法 [J]. 电力系统自动化, 2019, 43 (5) : 53-58.
- [16] Guo X, Stein B V. A New Approach Towards the Combined Algorithm Selection and Hyper-Parameter Optimization Problem [C] // Proceedings of the IEEE Symposium Series on Computational Intelligence, 2019.
- [17] 周莽, 高憧, 李晨光, 等. GRU 神经网络短期电力负荷预测研究 [J]. 科技创新与应用, 2018 (33) : 52-53.
- [18] 王守相, 陈海文, 蔡声霞. 一种基于门控循环单元网络的负荷聚合体预测方法: 109063911A [P]. 2018-08-03.
- [19] N.M.Hatta, Azlan M Z, Roselina S, et al. Recent Studies on Optimisation Method of Grey Wolf Optimiser (GWO) : A Review (2014-2017) [J]. Artificial Intelligence Review, 2019, 52 (4) : 2651-2683.