

doi: 10.3969/j.issn.1007-290X.2020.008.008

# 基于深度长短期记忆神经网络的短期负荷预测

王激华<sup>1</sup>, 仇钧<sup>1</sup>, 方云辉<sup>1</sup>, 周苏洋<sup>2</sup>

(1. 国网浙江省电力有限公司宁波供电公司, 浙江 宁波 315016; 2. 东南大学, 江苏 南京 211189)

**摘要:** 传统的短期电力负荷预测模型难以处理大数据量, 并且具有强随机性, 预测精度难以满足智能电网发展的要求。为此, 提出一种基于深度长短期记忆(deep long short-term memory, DLSTM)神经网络的数据驱动型短期负荷预测方法。使用该方法对某地区电力负荷进行预测, 并将预测结果与传统方法的预测结果进行对比分析。对比结果表明, 所提出的方法充分考虑了电力负荷的时序性和非线性, 能深入挖掘电力用户侧数据特征, 对电力负荷的短期预测性能优于传统方法, 满足智能电网对短期电力负荷预测的高精度要求。

**关键词:** 智能电网; 数据预测; 数据驱动; 深度长短期记忆神经网络; 深度学习

**中图分类号:** TM715.1; TP183

**文献标志码:** A

**文章编号:** 1007-290X(2020)08-0062-07

## Short Term Load Forecasting Based on Deep LSTM Neural Network

WANG Jihua<sup>1</sup>, QIU Jun<sup>1</sup>, FANG Yunhui<sup>1</sup>, ZHOU Suyang<sup>2</sup>

(1. State Grid Zhejiang Electric Power Co., Ltd. Ningbo Power Supply Company, Ningbo, Zhejiang 315016, China; 2. Southeast University, Nanjing, Jiangsu 211189, China)

**Abstract:** It is difficult to process large data volume by using traditional short term power load forecasting model which is provided with strong randomness and the forecasting accuracy is hard to satisfy the requirements of the smart grid. Therefore, this paper proposes a kind of data-driven short term load forecasting method based on the deep long short-term memory (DLSTM) neural network to predict power load in some area and make comparative analysis on the forecasting results with the results of the traditional method. The comparison results indicate the proposed method takes into full consideration of the time sequence and non-linear of power load and is feasible in deeply excavating data characteristics of power consumers. Meanwhile, the short term forecasting property of this method is superior to the traditional method and is able to meet the demand of the smart grid for high precision.

**Key words:** smart grid; load forecasting; data-driven; deep long short-term memory neural network; deep learning

负荷预测属于能量管理系统的重要组成部分, 是电力系统经济调度的一项重要内容<sup>[1]</sup>。精准的电网层级负荷预测有助于电力部门合理规划生产, 优化运行成本, 保持电网运行的安全稳定, 同时能减少不必要的旋转备用容量, 降低发电成本, 提高电网运行的经济性。随着电力市场的不断发展, 现货市场的改革对负荷预测精度的要求越来越高。精准的用户层级负荷预测有助于进行能源交易方法设计和现货市场报价, 以及制订中长期售电策略等; 因此, 精准的负荷预测是实现电力系统管理现代化、售电公司向现货市场转型的重要基础<sup>[2]</sup>。

按预测时间的不同, 负荷预测可以分为超短期、短期和中长期负荷预测。通常, 短期负荷预测会受各种非线性因素的影响, 例如待预测地区的气候条件、社会活动、经济情况和一些其他非常规的行为等。随着人们生活水平的提高, 社会经济活动日益丰富, 负荷波动水平明显增大。此外, 随着智能电网、通信网络技术和传感器技术的发展, 电力用户侧数据呈指数级增长<sup>[3]</sup>, 给传统负荷预测模型的数据处理能力带来巨大压力。这些不确定性因素使电改背景下更为精确的负荷预测成为一项亟需提升的技术。

为提高短期负荷预测的精度, 过去数十年间国内外学者提出了很多预测方法, 大致可分为经典预测算法和现代预测算法<sup>[4]</sup>。经典预测算法通常使用

收稿日期: 2020-03-09 修回日期: 2020-05-29

基金项目: 国网浙江省电力有限公司科技项目(5211NB1800MR)

早期的统计分析模型, 如趋势外推法<sup>[5-6]</sup>、时间序列法<sup>[7-8]</sup>、回归分析法<sup>[9-10]</sup>等, 这些方法对于平稳时间序列负荷信号有较好的预测效果, 但无法进行非线性拟合分析, 因此对于非平稳时间序列负荷信号的预测效果往往较差。

现代预测算法通常使用人工智能算法<sup>[11]</sup>进行预测。文献[12-14]使用支持向量回归(support vector machine regression, SVR)模型结合人工特征提取器构建了短期负荷预测模型, 在国内外地区的负荷预测上取得不错的效果; 文献[15]使用人工神经网络(artificial neural network, ANN)算法进行了不同场景下的短期负荷预测, 虽然效果较好但存在泛化能力较差的问题; 文献[16-17]分别建立了基于 BP 神经网络和 Elman 神经网络的短期负荷预测模型, 并针对上述 2 种算法的缺点进行了优化, 提高了算法的预测精度; 文献[18]使用决策树(decision trees, DT)对未来短期负荷进行概率上的拟合, 但存在精度较差的问题; 文献[19-20]分别使用随机森林(random forest, RF)算法和迭代决策树(gradient boosting decision tree, GBDT)算法建立了短期负荷预测模型, 并使用真实负荷数据进行了有效性验证。上述现有主流负荷预测算法在面对数量较大、随机性较强的数据时, 泛化能力较差且无法直接处理, 需要人工事先挑选特征, 造成有效信息的丢失, 进而导致预测精度无法满足智能电网的发展要求。

为解决上述问题, 文献[21]使用宽度和深度(Wide & Deep)模型对传统的循环神经网络(recurrent neural network, RNN)进行改进, 建立了深度学习短期负荷预测模型, 并在此基础上进行了日前台区负荷预测, 但该方法的预测精度仍有改进空间。本文提出一种完全数据驱动型的负荷预测方法, 该方法基于深度长短期记忆(deep long short-term memory, DLSTM)神经网络构建负荷预测模型, 使该模型既具备传统神经网络的泛化能力, 又能深度学习、挖掘时间序列中的信息, 避免在过长的离线训练中过早陷入局部最优。最后将该方法应用于美国新英格兰地区的负荷预测, 并将预测结果与现有主流算法进行了对比分析。

## 1 数据预处理

某地区的电力负荷通常与当地的自然条件、社会活动等息息相关, 因此负荷预测需要充分考虑可

能影响用电负荷的重要因素, 例如温度、湿度、节假日、工作日、历史负荷等, 这些因素均可称为特征变量。

设所有特征变量的历史数据集为  $C$ , 则该数据集可表示为

$$C = [C_1 \ C_2 \ \cdots \ C_k \ \cdots \ C_m], \quad (1)$$

式中  $C_k$  为第  $k$  ( $1 \leq k \leq m$ ) 维特征变量,  $m$  为负荷预测所考虑的特征变量维数。第  $k$  维特征变量  $C_k$  可进一步表示为

$$C_k = [C_k^{(1)} \ C_k^{(2)} \ \cdots \ C_k^{(j)} \ \cdots \ C_k^{(n)}], \quad (2)$$

式中  $C_k^{(j)}$  为第  $k$  维特征变量中第  $j$  ( $1 \leq j \leq n$ ) 个时间点的历史数据,  $n$  为特征变量的时间长度。

常规的数据驱动型负荷预测方法通常受限于自身算法的计算能力而不考虑时间维度信息。为提取历史数据中的时序特征用于负荷预测, 进一步提高短期负荷预测的精度, 本文采用 DLSTM 神经网络对历史时间序列数据进行深入挖掘。

由于负荷预测的特征变量较多, 且数据种类与结构相差较大, 为充分挖掘每一维特征变量的特征信息, 首先对历史数据按维度进行标准化, 设第  $k$  维特征变量标准化后为  $C_k^*$ , 则第  $k$  维特征变量中第  $j$  ( $1 \leq j \leq n$ ) 个时间点的历史数据的特征值  $C_k^{*(j)}$  可表示为

$$C_k^{*(j)} = \frac{C_k^{(j)} - \mu}{\sigma}, \quad (3)$$

式中  $\mu$  和  $\sigma$  分别为特征变量平均值和标准差。

然后对标准化后的历史时间序列数据使用长度为  $q$  的滑动窗口进行帧格化, 作为一个训练样本。设样本数据集为  $X$ , 则第  $i$  个训练样本

$$X_i = \begin{bmatrix} C_1^{*(i)} & C_2^{*(i)} & \cdots & C_m^{*(i)} \\ C_1^{*(i+1)} & C_2^{*(i+1)} & \cdots & C_m^{*(i+1)} \\ \vdots & \vdots & & \vdots \\ C_1^{*(i+q)} & C_2^{*(i+q)} & \cdots & C_m^{*(i+q)} \end{bmatrix}, \quad (4)$$

式中  $1 < q < h$ ,  $h$  为训练样本总数。设样本数据集  $X$  所对应的预测目标负荷值为  $Y$ , 则 DLSTM 神经网络的嵌入维输入数据集

$$D = [X \ Y]. \quad (5)$$

## 2 长短期记忆神经网络构建

长短期记忆(long short-term memory, LSTM)神经网络属于深度学习算法, 是特殊形式的 RNN 算法, 由 Hochreiter 和 Schmidhuber 在 1997 年首次提出, 并在近期被 Alex Graves 进行了改良和推广, 主要用于对序列数据中的长期依赖

信息进行学习和处理<sup>[22-25]</sup>。

LSTM 神经网络能提取序列数据中的长期依赖信息的关键, 在于其网络内部结构中各种类型控制门的灵活使用。LSTM 神经网络常见的控制门包括输入门、遗忘门和输出门, 其神经元典型结构如图 1 所示。图 1 中:  $t$  为时间点;  $i^{(t)}$  为输入门, 主要用于控制当前时刻网络的状态有多少信息需要保存到内部状态中;  $f^{(t)}$  为遗忘门, 主要用于控制过去的状态信息有多少需要丢弃;  $o^{(t)}$  为输出门, 主要用于控制当前时刻的内部状态有多少信息需要输出给外部状态;  $h^{(t)}$  为当前时刻神经元内部状态;  $c^{(t)}$  为当前时刻外部状态;  $x^{(t)}$  为当前时刻外部输入;  $\sigma$  为激活层函数。

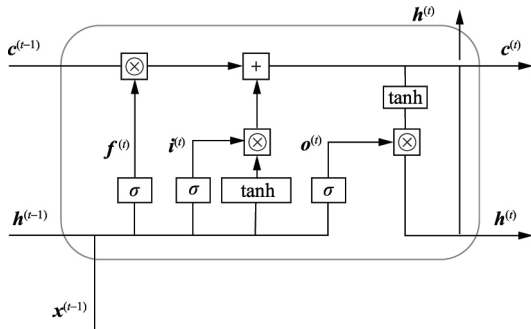


图 1 LSTM 神经元结构

Fig. 1 Structure of LSTM neuron

通过综合运用这 3 种控制门, LSTM 神经网络可以控制神经网络中传递信息的保留和丢弃, 并控制当前时刻新的状态信息有多少需要保存到记忆单元中。相比一般的神经网络, LSTM 神经网络可以学习跨度相对较长的依赖关系, 而不会出现梯度消失<sup>[26]</sup>和梯度爆炸<sup>[27]</sup>的问题。

为挖掘到更深层次的时间序列信息, 本文将多层 LSTM 神经网络进行顺序堆叠, 构建 DLSTM 神经网络, 其网络结构如图 2 所示, 其中  $T$  为 1 个数据帧的时间点个数。

由图 2 可知, 在 DLSTM 神经网络中, 每一层网络的隐藏层输出均作为下一层网络的输入。设 DLSTM 神经网络的层数为  $l$ , 则  $l$  层 DLSTM 神经网络的状态更新方式可表示为:

$$i_l^{(t)} = \sigma(W_{i,l}h_{l-1}^{(t)} + V_{i,l}h_l^{(t-1)} + b_{i,l}); \quad (6)$$

$$f_l^{(t)} = \sigma(W_{f,l}h_{l-1}^{(t)} + V_{f,l}h_l^{(t-1)} + b_{f,l}); \quad (7)$$

$$o_l^{(t)} = \sigma(W_{o,l}h_{l-1}^{(t)} + V_{o,l}h_l^{(t-1)} + b_{o,l}); \quad (8)$$

$$c_l^{(t)} = f_l^{(t)} \otimes c_{l-1}^{(t)} + \quad (9)$$

$$i_l^{(t)} \otimes \tanh(W_{c,l}h_{l-1}^{(t)} + V_{c,l}h_l^{(t-1)} + b_{c,l});$$

$$h_l^{(t)} = o_l^{(t)} \otimes \tanh(c_l^{(t)}). \quad (10)$$

式中:  $W$ 、 $V$ 、 $b$  为网络权重矩阵, 下标“i、f、o、c”分别对应 i、f、o 门和外部状态;  $\otimes$  表示内积运算。

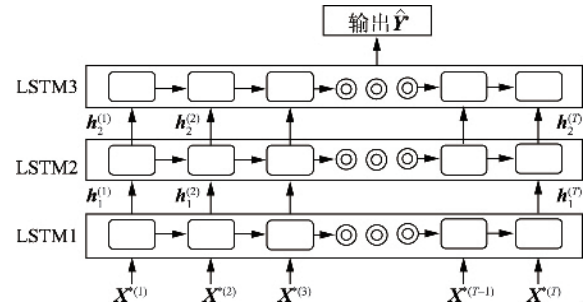


图 2 DLSTM 神经网络结构

Fig. 2 Structure of DLSTM

### 3 基于 DLSTM 神经网络的预测模型构建

本文所设计的电力负荷预测模型由嵌入维、DLSTM 神经网络以及逻辑回归层顺序堆叠而成, 其构建方法如图 3 所示, 其中  $s$  为迭代次数,  $S$  为算法训练前设定的迭代总次数,  $E(s)$  为第  $s$  次 softmax 回归函数值。

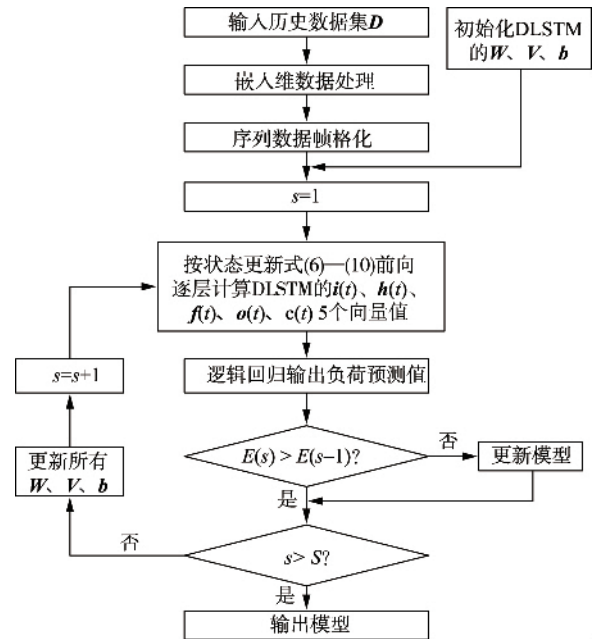


图 3 构建负荷预测模型的流程

Fig. 3 Flow chart of building a load forecasting model

负荷预测模型搭建完成后, 需要使用大量历史数据进行离线训练, 直至收敛后才能生成可用于实际负荷预测的稳定模型。通常离线训练计算量较大、用时较长、速度较慢, 但训练完成后在线使用时速度快、用时短, 与使用传统负荷预测算法差别不大。

## 4 实验

为验证本文所提出方法的有效性, 以美国新英格兰地区的负荷数据为例, 分别使用 DLSTM 神经网络、RNN、ANN、DT 对该地区进行负荷预测, 并对预测结果进行对比分析。数据均来源于 New England ISO 的公开数据集, 该数据源的详细下载链接为: <https://www.iso-ne.com/isoexpress/web/reports/load-and-demand/-/tree/zone-info>。

### 4.1 实验设置

使用新英格兰地区 2004—2009 年的负荷数据作为此次实验的数据集, 该数据集每小时采集 1 次, 共有 52 608 点数据。其中, 选择 2004—2007 年的数据作为历史数据集进行离线学习训练, 使用 2008—2009 年的数据作为验证数据集。

分别使用 DLSTM 神经网络、RNN、ANN、DT 预测 1 d 内 24 个点(每小时 1 个点)的负荷, 所有方法使用的敏感变量均为温度、湿度、时刻、上一周同时刻负荷量、前一天同时刻负荷量、前一天平均负荷量。不同的是, DLSTM 神经网络所使用的变量均为时间序列数据, 序列长度为 1 周共 168 点数据。

DLSTM 神经网络设置为 3 层, 神经元个数分别为 7、50、1, 训练算法为 adam, dropout 系数设为 0.2。RNN 的层数为 3 层, 神经元个数分别为 7、20、1, ANN 的层数和神经元个数与 RNN 相同。值得一提的是, 在实验过程中, 当 RNN 和 ANN 的隐藏层神经元设为与 DLSTM 神经网络一样的 50 个时训练极为缓慢, 且无法收敛, 在逐步减少神经元个数情况下才能正常运行, 故最终设为 20。DT 的树深度设为“None”。

### 4.2 实验指标

本文结合统计学误差分析与实际调度运行的需要, 主要使用均方根误差(root mean square error, RMSE)、平均绝对误差(mean absolute error, MAE)、平均绝对百分比误差(mean absolute percentage error, MAPE)、日峰值平均绝对百分比误差(daily peak MAPE, DPM)4 个指标作为本次实验结果评价指标, 其量符号分别为  $E_{\text{RMS}}$ 、 $E_{\text{MA}}$ 、 $E_{\text{MAP}}$ 、 $E_{\text{DPM}}$ 。

实验指标的定义如下:

$$E_{\text{RMS}} = \sqrt{\frac{1}{N} \sum_{p=1}^N (\hat{y}_p - y_p)^2}; \quad (11)$$

$$E_{\text{MA}} = \frac{1}{N} \sum_{p=1}^N |\hat{y}_p - y_p|; \quad (12)$$

$$E_{\text{MAP}} = \frac{1}{N} \sum_{p=1}^N \left| \frac{\hat{y}_p - y_p}{y_p} \right|; \quad (13)$$

$$E_{\text{DPM}} = \left| \frac{\hat{y}_{\text{max}} - y_{\text{max}}}{y_{\text{max}}} \right|. \quad (14)$$

式中:  $N$  为预测负荷的总点数;  $\hat{y}_p$  为预测负荷;  $y_p$  为实际负荷;  $\hat{y}_{\text{max}}$  为预测日负荷峰值;  $y_{\text{max}}$  为实际日负荷峰值。

由上述定义可知:  $E_{\text{RMS}}$ 、 $E_{\text{MA}}$ 、 $E_{\text{MAP}}$  和  $E_{\text{DPM}}$  的值越小, 表示预测值与真实值越吻合, 模型越完美; 反之则代表预测值与实际值差别越大, 预测效果越差。

### 4.3 实验结果及分析

为验证所提出方法的有效性, 分别使用 DLSTM 神经网络、RNN、ANN 和 DT 对新英格兰地区 2008—2009 年的日负荷数据进行预测, 预测结果见表 1。

表 1 采用不同方法预测结果

Tab. 1 Forecasting results using different methods

方法	$E_{\text{RMS}}/\text{MWh}$	$E_{\text{MA}}/\text{MWh}$	$E_{\text{MAP}}/\%$	$E_{\text{DPM}}/\%$
DLSTM 神经网络	376.10	275.64	1.66	1.58
RNN	431.26	330.33	2.26	2.02
ANN	461.37	350.63	2.40	2.08
DT	517.41	376.77	2.56	2.36

首先对预测结果进行横向对比分析。由表 1 可知, 使用 DLSTM 神经网络进行预测, 其预测结果的  $E_{\text{RMS}}$  为 376.10 MWh, 比 RNN 的 431.26 MWh、ANN 的 461.37 MWh 以及 DT 的 517.41 MWh 分别低 12.79%、18.48%、27.31%。同时, DLSTM 神经网络的  $E_{\text{MA}}$  为 275.64 MWh, 也是 4 种方法中的最小值。

此外, DLSTM 神经网络的  $E_{\text{MAP}}$  降至 1.66%, 低于 RNN 的 2.26%、ANN 的 2.40% 和 DT 的 2.56%。DLSTM 神经网络对日负荷峰值的预测也比其他方法更为精准,  $E_{\text{DPM}}$  仅有 1.58%, 分别比 RNN、ANN 和 DT 降低 21.78%、24.04% 和 33.05%。

从以上实验指标数值的横向对比不难发现: DLSTM 神经网络、RNN、ANN 这 3 种方法的负荷预测结果要优于 DT; 可从时间序列数据中挖掘特征信息的 DLSTM 神经网络和 RNN 的负荷预测结果优于无法处理时间序列的 ANN 和 DT; 采用了深度学习架构进行改进的 DLSTM 神经网络, 其负荷预测性能比 RNN 也有了明显改进。

为了更直观地对比 4 种方法的预测效果, 以新英格兰地区 2009 年 1 月 16—23 日的日负荷预测结

果为例, 其预测值和真实值的对比以及相关残差如图 4、图 5 所示。




图 4 日负荷预测结果与真实值对比(2009 年)

Fig. 4 Comparison of load forecasting results with real values(in 2009)




图 5 日负荷预测结果残差对比(2009 年)

Fig. 5 Comparison of load forecasting result residuals(in 2009)

由图 4 可知, 在 2009 年 1 月 16—23 日一周时间内, DLSTM 神经网络的日负荷预测曲线与真实的负荷曲线最为贴近, 几乎重合; 从图 5 则可进一步发现 DLSTM 的残差也一直在 0 附近波动。4 种方法中, DLSTM 神经网络的预测准确度和稳定度均为最高。

接着再单独针对 DLSTM 神经网络的预测结果进行纵向对比分析。DLSTM 神经网络的全部预测结果残差分布如图 6 所示。




图 6 DLSTM 神经网络日负荷预测结果残差分布

Fig. 6 Residual error distribution of load forecasting results of DLSTM

由图 6 可知, DLSTM 神经网络的预测残差基本满足正态分布, 其预测结果较为真实可信。

进一步地按日、周分别进行相关残差统计分析, 得到图 7、图 8 所示的箱形图。




图 7 按日统计残差箱形图

Fig. 7 Residual box plot by hours

由图 7 可知 DLSTM 神经网络对该地区 09:00—16:00 之间负荷的预测异常值较少, 结果较为精确。这与 09:00—16:00 通常为工作时间, 用电负荷较为稳定有关。而观察一天中的负荷趋势不难发现, 该地区 13:00—19:00 的负荷通常较大。




图 8 按周统计残差箱形图

Fig. 8 Residual box plot by weeks

由图 8 可知, DLSTM 神经网络对该地区星期四、星期五的负荷预测异常值较多, 预测较为困难。

## 5 结束语

为解决传统的短期电力负荷预测方法难以处理大数据量和强随机性导致精度难以满足现状的问题, 本文提出了一种完全数据驱动的 DLSTM 神经网络短期负荷预测方法。为验证该方法的有效性,

将该方法与目前常用的几种方法同时应用于美国新英格兰地区的负荷预测,并对预测结果进行了横向和纵向对比分析。最终对比结果表明,本文所提出的方法比目前常用的 RNN、ANN 和 DT 具有更高的准确度和稳定度,且能很好地学习适应不同地区的电力负荷特点,具有很强的泛化能力。

#### 参考文献:

- [1] 邓欣宇,王守相,郭陆阳,等. 人工智能方法在配用电领域的应用[J]. 供用电, 2019, 36(1): 3-9.  
DENG Xinyu, WANG Shouxiang, GUO Luyang, et al. An overview of the application of artificial intelligence methods in the field of power distribution and utilization[J]. Distribution & Utilization, 2019, 36(1): 3-9.
- [2] 李昭昱,艾芊,张宇帆,等. 基于 attention 机制的 LSTM 神经网络超短期负荷预测方法[J]. 供用电, 2019, 36(1): 17-22.  
LI Zhaoyu, AI Qian, ZHANG Yufan, et al. A LSTM neural network method based on attention mechanism for ultra short-term load forecasting[J]. Distribution & Utilization, 2019, 36(1): 17-22.
- [3] 王德文,孙志伟. 电力用户侧大数据分析与并行负荷预测[J]. 中国电机工程学报, 2015, 35(3): 527-537.  
WANG Dewen, SUN Zhiwei. Big data analysis and parallel load forecasting on the power user side[J]. Proceedings of the CSEE, 2015, 35(3): 527-537.
- [4] 胡娱欧,张艳馥,张永强. “十三五”期间华北电网负荷预测研究[J]. 电气技术, 2016, 17(5): 11-15.  
HU Yu'ou, ZHANG Yanfu, ZHANG Yongqiang. Study on load forecasting of north China power grid during the “13th Five-Year Plan” period[J]. Electrical Technology, 2016, 17(5): 11-15.
- [5] 颜金木. 基于趋势外推法的电力负荷预测[J]. 中国外资, 2011(4): 228-228.  
YAN Jinmu. Power load forecasting based on trend extrapolation [J]. China Foreign Investment, 2011(4): 228-228.
- [6] 夏昌浩,曹瑾,张密,等. 电力负荷趋势外推预测算例分析与模型检验[J]. 中国科技信息, 2016(21): 90-92.  
XIA Changhao, CAO Jin, ZHANG Mi, et al. Analysis and model verification of power load trend extrapolation forecasting examples [J]. China Science and Technology Information, 2016(21): 90-92.
- [7] 张帆,张峰,张士文. 基于提升小波的时间序列分析法的电力负荷预测[J]. 电气自动化, 2017, 39(3): 72-76.  
ZHANG Fan, ZHANG Feng, ZHANG Shiwen. Time series analysis method based on lifting wavelet for power load forecasting[J]. Electric Automation, 2017, 39(3): 72-76.
- [8] 陈冬洋,郑丹,吴永峰. 基于时间序列的电力系统短期负荷预测问题分析[J]. 自动化应用, 2017(11): 99-101.
- [9] 吕福琴. 基于自回归和神经网络算法加权组合的负荷预测[J]. 广东电力, 2011, 24(5): 69-72, 102.  
LÜ Fuqin. Load forecasting based on weighted combination of autoregressive and neural network algorithms[J]. Guangdong Electric Power, 2011, 24(5): 69-72, 102.
- [10] 陈毅波,郑玲,姚建刚. 基于粗糙集理论与 D-S 证据理论改进的多元回归负荷预测方法研究[J]. 电力系统保护与控制, 2016, 44(6): 62-67.  
CHEN Yibo, ZHENG Ling, YAO Jiangang. Research on multiple regression load forecasting method based on rough set theory and D-S evidence theory improvement[J]. Power System Protection and Control, 2016, 44(6): 62-67.
- [11] 朱永利,尹金良. 人工智能在电力系统中的应用研究与实践综述[J]. 发电技术, 2018, 39(2): 106-111.  
ZHU Yongli, YIN Jinliang. Review of research and practice of artificial intelligence application in power systems[J]. Power Generation Technology, 2018, 39(2): 106-111.
- [12] 钱志. 基于改进型 SVR 的电网短期负荷预测[J]. 中国电力, 2016, 49(8): 54-58.  
QIAN Zhi. Short-Term Power Load Forecasting Based on Improved SVR [J]. Electric Power, 2016, 49(8): 54-58.
- [13] 蒋敏,顾东健,孔军,等. 基于在线序列极限支持向量回归的短期负荷预测模型[J]. 电网技术, 2018, 42(7): 2240-2247.  
JIANG Min, GU Dongjian, KONG Jun, et al. Short-term load forecasting model based on online sequence limit support vector regression [J]. Power System Technology, 2018, 42(7): 2240-2247.
- [14] LI M S, WU J L, JI T Y, et al. Short-term load forecasting using support vector regression-based local predictor[C]//Power & Energy Society General Meeting. Piscataway: IEEE Press, 2015.
- [15] DEHALWAR V, KALAM A, KOLHE M L, et al. Electricity load forecasting for Urban area using weather forecast information[C]//IEEE International Conference on Power & Renewable Energy. Piscataway: IEEE Press, 2016.
- [16] 陈亚,李萍. 基于神经网络的短期电力负荷预测仿真研究[J]. 电气技术, 2017, 18(1): 26-29.  
CHEN Ya, LI Ping. Simulation study of short-term power load forecasting based on neural network [J]. Electrical Technology, 2017, 18(1): 26-29.
- [17] 王玉龙,崔玉,李鹏,等. 基于小波分析改进的神经网络模型电力系统负荷预测[J]. 电网与清洁能源, 2015, 31(2): 16-20, 27.  
WANG Yulong, CUI Yu, LI Peng, et al. Load forecasting of power system based on improved neural network model based on wavelet analysis [J]. Power System and Clean Energy, 2015, 31(2): 16-20, 27.
- [18] HAMBALI A O J, AKINYEMI M, JYUSUF N. Electric power load forecast using decision tree algorithms [J]. Computing, Information Systems, Development Informatics and Allied Research Journal, 2016(4): 29-42.
- [19] 吴潇雨,和敬涵,张沛,等. 基于灰色投影改进随机森林算

- 法的电力系统短期负荷预测[J]. 电力系统自动化, 2015, 39(12): 50-55.
- WU Xiaoyu, HE Jinghan, ZHANG Pei, et al. Short-term load forecasting of power systems based on gray projection improved random forest algorithm [J]. Automation of Electric Power Systems, 2015, 39(12): 50-55.
- [20] 郑凯文, 杨超. 基于迭代决策树(GBDT)短期负荷预测研究[J]. 贵州电力技术, 2017, 20(2): 82-84, 90.
- ZHENG Kaiwen, YANG Chao. Research on short-term load forecasting based on iterative decision tree (GBDT) [J]. Guizhou Electric Power Technology, 2017, 20(2): 82-84, 90.
- [21] 吕海灿, 王伟峰, 赵兵, 等. 基于 Wide&Deep-LSTM 模型的短期台区负荷预测[J]. 电网技术, 2020, 44(2): 428-436.
- LÜ Haican, WANG Weifeng, ZHAO Bing, et al. Short-term substation load forecast based on wide & deep-LSTM model [J]. Power System Technology, 2020, 44(2): 428-436.
- [22] 余达. 基于深度学习的风力发电系统故障在线诊断研究[D]. 广州: 华南理工大学, 2018.
- [23] LI M, YU D, CHEN Z, et al. A data-driven residual-based method for fault diagnosis and isolation in wind turbines[J]. IEEE Transactions on Sustainable Energy, 2018, 10(2): 895-904.
- [24] 刘达, 雷自强, 孙堃. 基于小波包分解和长短期记忆网络的短期电价预测[J]. 智慧电力, 2020, 48(4): 77-83.
- LIU Da, LEI Ziqiang, SUN Kun. Short-term electricity price prediction based on wavelet packet decomposition and long-term short-term memory network [J]. Smart Power, 2020, 48(4): 77-83.
- [25] 郎伟明, 麻向津, 周博文, 等. 基于 LSTM 和非参数核密度估计的风电功率概率区间预测[J]. 智慧电力, 2020, 48(2): 31-37, 103.
- LANG Weiming, MA Xiangjin, ZHOU Bowen, et al. Wind power probability interval prediction based on LSTM and non-parametric kernel density estimation [J]. Smart Power, 2020, 48(2): 31-37, 103.
- [26] SCHMIDHUBER J. Gradient flow in recurrent nets: the difficulty of learning long-term dependencies[C]//Gradient Flow in Recurrent Nets: The Difficulty of Learning Long

Term Dependencies. [S. l.]: Wiley-IEEE Press, 2001.

- [27] GOH G B, HODAS N O, VISHNU A. Deep learning for computational chemistry [J]. Journal of Computational Chemistry, 2017, 38(16): 1291-1307.

#### 项目简介:

申请单位 国网浙江省电力有限公司宁波供电公司

项目名称 以用户为导向的综合能源系统服务模式及相关支撑技术研究

项目概述 包含电、气、冷、热的综合能源服务需要综合考虑异质能源的转换、输送、存储及使用等多方面因素。在保障综合能源系统安全稳定运行的前提下,为综合能源用户提供定制化、高效化、经济化的服务模式,对于提升电网公司的客户服务能力、巩固公司售电市场及扩展电网公司业务范围具有重要意义。项目重点研究以用户为导向的综合能源系统服务模式。立足于综合能源系统内用户对于异质能源的差异化需求,着眼于综合能源用户的多样化设备典型运行配置,考虑综合能源系统的供给能力,建立满足终端客户多元化能源生产与消费的综合能源服务方式。

主要创新点 ①创新不同时空状态下的综合能源用户用能特征模型构建,为综合能源服务模式提供定制化的需求信息,为综合能源用户提供全景的用能特性分析;②创新面向多样化运营场景的综合能源用户运行优化策略生成,提高综合能源服务的质量和效率;③创新研究差异化场景下的综合能源系统最优服务模式,为用户提供安全性及经济性最优的综合能源服务选择。

#### 作者简介:

王激华(1972),男,浙江宁波人,高级工程师,主要从事电网技术、综合能源技术研究, E-mail: 15830557817@139.com。

仇钧(1971),男,浙江宁波人,高级工程师,硕士,主要从事电网营销、综合能源技术研究, E-mail: 17714323231@139.com。

方云辉(1982),男,浙江诸暨人,高级工程师,硕士,主要从事综合能源技术研究, E-mail: 13957890959@139.com。

周苏洋(1987),男,江苏连云港人,讲师,博士,长期从事综合能源系统的规划仿真及运行优化研究, E-mail: suyang.zhou@seu.edu.cn。

(编辑 彭艳)